

在 Azure Databricks 中, Koalas 的核心作用就是用 **Pandas** 的语法无缝运行 **Spark** 的分布式计算引擎。自 Spark 3.2 (以及 Azure Databricks Runtime 10.0+) 开始, Koalas 已被官方正式整合并内置为 **pyspark.pandas** (通常称为 *Pandas API on Spark*)。

无缝衔接的三大体现

- **零成本语法迁移**: 你可以直接使用熟悉的 Pandas 语法 (如 `df.groupby().mean()`、`df.describe()`) 处理海量数据, 底层会自动转化为 Spark DataFrame 的分布式执行计划。
- **工作流无缝融合**: 在一个 Notebook 中, 你可以先用 PySpark 极速加载 ADLS 中的 TB 级原始数据, 转为 `pandas_api()` 做数据特征工程, 最后将转换好的 Spark DataFrame 直接送入 MLflow 建模。
- **示例代码自由转换**:

```
import pandas as pd
from pyspark.sql import functions as F
from pyspark.sql.types import StructType, StructField, DoubleType,
ArrayType
import pyspark.pandas as ps
```

1. 单机 Pandas DataFrame -> PySpark DataFrame

```
pdf = pd.DataFrame()
df_spark = spark.createDataFrame(pdf)
```

2. PySpark DataFrame ↔ Pandas API (Koalas)

```
psdf = df_spark.pandas_api()
df_spark = psdf.to_spark()
```

3. Pandas API ↔ 单机 Pandas DataFrame

```
pdf = psdf.to_pandas()
psdf = ps.from_pandas(pdf)
```

单机 Pandas 与 pyspark.pandas 互相转换

pyspark.pandas.from_pandas / to_pandas

https://spark.apache.org/docs/latest/api/python/tutorial/pandas_on_spark/pandas_pyspark.html

核心技术对比

维度	原生 Pandas	pyspark.pandas (原 Koalas)	原生 PySpark DataFrame
语法风格	单机 Pandas API	Pandas API	PySpark DSL / Spark SQL
底层引擎	单机内存 (Single-node)	分布式 Spark 引擎	分布式 Spark 引擎
处理数据量	受限于单机内存 (GB 级)	分布式扩展 (TB / PB 级)	分布式扩展 (TB / PB 级)
索引 (Index)	强依赖显式 Index	模拟实现 Index	无显式 Index 概念

需要注意的“非完全无缝”细节

- 索引 (Index) 开销: Pandas 依赖严格有序的行索引, 而分布式 Spark 默认是不保序的。在 pyspark.pandas 中, 默认的索引策略 (如 sequence) 可能会带来额外的全局排序和 Shuffle 性能开销。
- 内存溢出风险 (OOM): 当调用 .to_pandas() 将分布式数据拉回单机时, 数据会全部集聚到 Driver 节点, 若数据体积超过 Driver 内存会导致崩溃。
- API 覆盖率: 覆盖了 85%+ 以上的高频 Pandas 函数, 但极少数不适合分布式架构的复杂单机函数 (如某些非常特殊的行级迭代 API) 仍无法直接使用。