

投资组合方差最小化的数学模型

设投资组合包含 n 种资产，定义参数如下：

- $w = [w_1, w_2, \dots, w_n]^T \in \mathbb{R}^n$ ：各资产的投资权重向量
- $\Sigma \in \mathbb{R}^{n \times n}$ ：资产收益率的协方差矩阵
- $e = [1, 1, \dots, 1]^T \in \mathbb{R}^n$ ：元素全为 1 的列向量
- $\mu = [\mu_1, \mu_2, \dots, \mu_n]^T \in \mathbb{R}^n$ ：各资产的期望收益率向量（可选）

最小化投资组合方差的数学优化问题可表达为：

$$\begin{aligned} \min_w \quad & \frac{1}{2} w^T \Sigma w \\ \text{s.t.} \quad & e^T w = 1 \\ & w \geq 0 \end{aligned}$$

注：若有目标收益率限制，可增加线性约束 $\mu^T w \geq \bar{\mu}$ 。

数学证明：为什么优化问题属于二次规划 (QP)

1. 标准二次规划 (Quadratic Programming, QP) 的定义

在最优化理论中，标准二次规划问题的通用形式定义为：

$$\begin{aligned} \min_x \quad & \frac{1}{2} x^T P x + q^T x \\ \text{s.t.} \quad & A x \leq b \\ & F x = g \end{aligned}$$

其中 P 必须为对称半正定矩阵 ($P \geq 0$)， A 与 F 为线性映射矩阵。

2. 映射与变量对照

将投资组合方差最小化问题与标准二次规划形式进行逐项映射：

- 决策变量**：令 $x = w$ 。
- 二次项系数矩阵**：令 $P = \Sigma$ ，目标函数可写成 $\frac{1}{2} w^T \Sigma w$ 。
- 一次项系数向量**：令 $q = \mathbf{0}$ （零向量，即没有线性项）。
- 等式约束**：令 $F = e^T$ ， $g = 1$ ，映射为 $e^T w = 1$ （资金全部投出的归一化约束）。

- **不等式约束:** 令 $A = -I_n$ (n 阶单位矩阵的负数), $b = \mathbf{0}$, 映射为 $-I_n w \leq \mathbf{0} \Leftrightarrow w \geq \mathbf{0}$ (禁止做空约束)。

3. 凸性证明 (半正定性)

二次规划要求目标函数的二次项系数矩阵 P 必须是半正定的。

对任意非零向量 $v \in \mathbb{R}^n$, 假设随机收益率向量为 R , 其均值为 μ , 则根据协方差矩阵的定义:

$$v^T \Sigma v = v^T \mathbb{E}[(R - \mu)(R - \mu)^T] v = \mathbb{E}[(v^T(R - \mu))^2]$$

因为实数平方的期望值必然非负, 所以对于任意 $v \neq 0$, 均有:

$$v^T \Sigma v \geq 0$$

这证明了协方差矩阵 Σ 是**对称半正定矩阵** ($\Sigma \geq 0$)。因此, 目标函数 $f(w) = \frac{1}{2} w^T \Sigma w$ 是一个**凸函数 (Convex Function)**, 保证了局部最优解即为全局最优解。

4. 约束条件的线性特征

- **权重和约束** $e^T w = \sum_{i=1}^n w_i = 1$ 是关于 w 的一次多项式, 构成一个线性超平面。
- **禁止做空约束** $w_i \geq 0$ 是一组线性不等式, 限定了可行域为正半空间。

目标函数由对称半正定矩阵构成的二次型 $w^T \Sigma w$ 决定, 且所有限制条件完全由线性等式与线性不等式组成, 因此该问题在数学上严格符合**线性约束二次规划 (Linearly Constrained Quadratic Programming)** 的标准定义。

$$W^*{}^T \Sigma W^* = \frac{|T(\Sigma^{-1})| \Sigma \Sigma^{-1}}{(|T(\Sigma^{-1})|)^2} = \frac{1}{|T(\Sigma^{-1})|}.$$

工程应用：数值解

当协方差矩阵 Σ 为半正定 (Semi-definite) 而非严格正定 (Positive-definite) 时, 说明存在特征值为 0。这在工程上意味着某些资产之间存在完全线性相关, 或者资产数量 N 大于样本时间步长 T (数据维度灾难)。

此时 Σ 不可逆, 无法直接计算 Σ^{-1} , 上述解析解 $w^* = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}$ 失效。

针对这种情况, 数学和工程上有以下 3 种标准解法:

解法一：伪逆法 (Moore-Penrose Pseudoinverse) ——保持数学解析解

用伪逆矩阵 Σ^+ 代替传统的逆矩阵 Σ^{-1} 。

1. 奇异值分解 (SVD):

将半正定矩阵分解为:

$$\Sigma = V \Lambda V^T$$

其中 $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_r, 0, \dots, 0)$, $\lambda_i > 0$ 为非零特征值。

2. 计算伪逆 Σ^+ :

$$\Sigma^+ = V \Lambda^+ V^T$$

其中 $\Lambda^+ = \text{diag}(\frac{1}{\lambda_1}, \frac{1}{\lambda_2}, \dots, \frac{1}{\lambda_r}, 0, \dots, 0)$ (只对非零特征值求倒数, 零特征值保持为 0)。

3. 代回解析解:

$$w^* = \frac{\Sigma^+ \mathbf{1}}{\mathbf{1}^T \Sigma^+ \mathbf{1}}$$

- 特点:** 形式上保留了解析解, 本质上是取所有满足最小方差的解中, 矩阵范数最小的那个解。

解法二：Ledoit-Wolf 缩减法 / 岭回归 (Shrinkage Regularization) ——工程最常用

通过在对角线上加入一个极小的正数 (正则化项), 强制将半正定矩阵修正为严格正定矩阵。

1. 构造修正矩阵:

$$\Sigma_{\text{shrunk}} = \Sigma + \gamma \mathbf{I}$$

- $\mathbf{I}$ 为单位矩阵。
- $\gamma > 0$ 为微小的扰动因子 (如 $\gamma = 10^{-5}$)。

2. 代回标准解析公式:

因为 Σ_{shrunk} 必然严格正定且可逆, 直接求解:

$$w^* = \frac{\Sigma_{\text{shrunk}}^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma_{\text{shrunk}}^{-1} \mathbf{1}}$$

- 特点:** 在量化金融与信号处理领域最普及, 极大地提高了矩阵求解的数值稳定性 (Numerical Stability)。

解法三：降维剔除法 (Dimensionality Reduction) ——消除冗余资产

半正定意味着资产组合中存在冗余 (完全共线性) 资产 (例如资产 B 的收益率永远等于资产 A 的 2 倍)。

- 计算 Σ 的秩 $r = \text{rank}(\Sigma) < N$ 。
- 识别出完全共线性的线性组合, 剔除掉 $N - r$ 个冗余资产, 得到 $r \times r$ 的子矩阵 Σ_r 。
- 对保留的 r 个独立资产求解标准解析解 w_r^* , 冗余资产的权重设置为 0 或通过线性组合按比例分配。

总结选择建议

解决策略	适用场景	Python / PySpark 实现工具
Ledoit-Wolf 缩减	强烈推荐（工业级标准，稳定性最好）	sklearn.covariance.LedoitWolf 或 np.linalg.inv(sigma + 1e-5 * np.eye(N))
伪逆法	仅做理论推导或保留全量资产维度	np.linalg.pinv(sigma)
降维剔除	数据集维度极高（如 $N \gg T$ ）	主成分分析（PCA）或矩阵 QR 分解